

# Lernunterlagen zur DSI-Prüfung

Strukturierte Vorbereitung zu den 30 geprüften Themen  
– mit Erklärungen, Definitionen, Beispielen,  
prüfungsrelevanten Punkten und Lern-  
Zusammenfassungen.

30 Prüfungsthemen

Reihenfolge gemäss Themenübersicht

Basis: eigene Zusammenfassung

# Themenübersicht

---

- |    |                           |    |                                     |
|----|---------------------------|----|-------------------------------------|
| 1  | VSM vs. System Dynamics   | 16 | Requisite Variety                   |
| 2  | Ashby Adaptation          | 17 | System Dynamics                     |
| 3  | Data Science Distinction  | 18 | Smart Factory                       |
| 4  | Real-Time Adaptive Models | 19 | Performance Model-Evaluation        |
| 5  | Overfitting               | 20 | Unsupervised Algorithm              |
| 6  | Visualization             | 21 | Target Centric Approach             |
| 7  | Complexity Examples       | 22 | Clustering & Network Analysis       |
| 8  | Class Weighting           | 23 | Hype Myths in Data Science          |
| 9  | Target-Oriented Action    | 24 | EDA                                 |
| 10 | Explainability of Models  | 25 | Ashby Misinterpretation             |
| 11 | Ashby Control             | 26 | VUCA Environment                    |
| 12 | Viable System Model       | 27 | Type of Learner                     |
| 13 | Class Imbalance           | 28 | Biases                              |
| 14 | Uncertainty Scenarios     | 29 | VSM Early Warning                   |
| 15 | Unsupervised Learning     | 30 | Interdisciplinarity in Data Science |

**Wie du diese Unterlagen nutzt:** Die Themen folgen exakt der Reihenfolge deiner Prüfungs-Übersicht. Jedes Thema ist gleich aufgebaut – **Erklärung** der Kernkonzepte, **Definitionen & Begriffe**, **Beispiel**, **prüfungsrelevante Punkte / typische Fragen** (orange) und eine **kompakte Lern-Zusammenfassung** (grau). Mehrere Prüfungsthemen behandeln verwandte Konzepte (z. B. Ashby in Thema 2, 11, 16, 25; VSM in 1, 12, 29) – die Wiederholungen sind bewusst gesetzt, damit du jede einzelne Fragestellung gezielt beantworten kannst.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Beide Ansätze stammen aus dem **Systemdenken (Systems Thinking)** und helfen, komplexe Systeme zu verstehen und zu steuern – sie tun das aber auf unterschiedliche Weise und beantworten unterschiedliche Fragen.

Das **Viable System Model (VSM)** von Stafford Beer ist eine **rekursive Management- bzw. Organisationsstruktur**. Es beschreibt, wie ein „überlebensfähiges“ (viable) System aufgebaut sein muss, damit es in einer veränderlichen Umwelt bestehen kann. Es ist eher ein *Bauplan für Steuerung und Lebensfähigkeit*: Subsysteme überwachen und regulieren sich gegenseitig über mehrere Rekursionsebenen, und es enthält **anti-oszillatorische Feedback-Loops**, die Anpassung, Lernen und Systemgesundheit sichern.

**System Dynamics (SD)** nach Jay Forrester ist dagegen eine **simulationsbasierte Modellierungs-Methode**. Sie untersucht, *wie sich ein System über die Zeit verhält*, und nutzt dazu Bausteine wie Stocks (Bestände), Flows (Flüsse), Feedback-Loops, Verzögerungen (delays) und Nichtlinearität. SD kombiniert qualitative Einsichten mit quantitativer Modellierung (z. B. in Vensim/STELLA).

### DEFINITIONEN & BEGRIFFE

- **VSM:** rekursive Management-Struktur für komplexe Systeme; sichert Lebensfähigkeit durch ineinander verschachtelte Steuerungs- und Feedback-Mechanismen.
- **System Dynamics:** Methodik zur Modellierung/Simulation des zeitlichen Verhaltens von Systemen über Stocks, Flows und Feedback.
- **Feedback-Loop:** Mechanismus, der Outputs als Inputs zurückführt; *balancing/negativ* („je mehr A, desto weniger B“) oder *reinforcing/positiv* („je mehr A, desto mehr B“).
- **Stocks & Flows:** Stocks = Akkumulationen (z. B. Lagerbestand); Flows = Änderungsraten (z. B. Verkäufe/Tag).
- **Delay:** Zeitverzögerung, die das Systemverhalten verändert.

## ► VERGLEICH AUF EINEN BLICK

| Dimension     | Viable System Model (VSM)                                                                                                        | System Dynamics (SD)                         |
|---------------|----------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------|
| Charakter     | Struktur-/Organisationsmodell                                                                                                    | Simulations-/Modellierungsmethode            |
| Leitfrage     | Wie bleibt ein System steuerbar & lebensfähig?                                                                                   | Wie verändert sich das System über die Zeit? |
| Bausteine     | Rekursionsebenen, Subsysteme, anti-oszillatorische Loops                                                                         | Stocks, Flows, Feedback-Loops, Delays        |
| Fokus         | Steuerung, Regulierung, Lernen                                                                                                   | Verhalten, Dynamik, Vorhersage               |
| Gemeinsamkeit | Beide beruhen auf <b>Feedback</b> und ganzheitlichem Systemdenken; oft gemeinsam genutzt (Recursive VSM + Control-Loop-Modelle). |                                              |

### BEISPIEL

**VSM:** Ein Konzern mit Geschäftsbereichen, die sich gegenseitig überwachen und steuern; eine zentrale Einheit greift nur bei Instabilität ein. **SD:** Ein Vensim-Modell einer Lieferkette, das den *Bullwhip-Effekt* (aufschaukelnde Bestellschwankungen durch Delays und Feedback) sichtbar macht.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- „Worin unterscheiden sich VSM und System Dynamics?“ → VSM = **Struktur** für Lebensfähigkeit, SD = **Methode** für zeitliches Verhalten.
- Gemeinsamkeit nennen können: beide nutzen **Feedback-Loops** und Systemdenken.
- Begriffe Stocks/Flows, balancing vs. reinforcing loop, Delay korrekt zuordnen.
- Wann welches Werkzeug? VSM zur Organisations-/Steuerungsanalyse, SD zur Simulation komplexer Dynamiken.

### KOMPAKT ZUM LERNEN

- **VSM = Aufbau/Steuerung** (lebensfähige Organisation, rekursiv, Beer).
- **SD = Verhalten über Zeit** (Stocks, Flows, Feedback, Delays, Forrester).
- Verbindendes Element: **Feedback**.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Ashbys Gesetz der erforderlichen Varietät** lautet sinngemäss: „*Only variety can absorb variety.*“ Ein System (natürlich oder künstlich) kann seine Umwelt nur dann beherrschen, wenn es mindestens so viel **innere Varietät (Komplexität)** besitzt wie die Umwelt, die es bewältigen muss. **Anpassung (Adaptation)** bedeutet genau dies: das System erhöht laufend seine eigene Varietät bzw. Steuerungskapazität, um mit der Vielfalt und Veränderlichkeit der Umwelt mitzuhalten.

Übersteigt die Varietät/Komplexität der Umwelt die Kapazität des Systems, dann **dominiert die Umwelt und zerstört das System letztlich**. Anpassung lässt sich auf zwei Wegen erreichen: die **eigene Varietät erhöhen** (Amplifikation, z. B. mehr Sensoren, mehr Modelle, mehr Handlungsoptionen) oder die **Umweltvarietät reduzieren/filtern** (Attenuation, z. B. Standardisierung, Fokussierung). Data Science ist ein Mittel, um die Umwelt besser zu „lesen“ und die eigene Kapazität zur Bewältigung von Komplexität zu erhöhen.

### DEFINITIONEN & BEGRIFFE

- **Varietät (variety):** Anzahl unterscheidbarer Zustände eines Systems bzw. seiner Umwelt = Mass für Komplexität.
- **Requisite Variety:** Mindest-Varietät, die ein Controller braucht, um ein System zu steuern.
- **Adaptation:** dynamische Angleichung der eigenen Varietät an die Umweltvarietät.
- **Amplifikation:** eigene Varietät erhöhen. **Attenuation:** Umweltvarietät reduzieren/filtern.

### BEISPIEL

Ein Unternehmen in einem volatilen Markt (hohe Umweltvarietät) passt sich an, indem es mehr Datenquellen erschliesst, flexiblere Prozesse einführt und adaptive Modelle nutzt (Amplifikation) und gleichzeitig sein Produktportfolio fokussiert (Attenuation). So bleibt die Steuerungskapazität  $\geq$  der Marktkomplexität.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Ashbys Gesetz in einem Satz: **nur Varietät kann Varietät absorbieren.**
- Was passiert bei zu wenig Varietät? → Umwelt dominiert/„zerstört“ das System (Bezug zu *fatal undercomplexity*, vgl. Thema 7 & 26).
- Zwei Anpassungsstrategien nennen: Varietät erhöhen (Amplifikation) vs. reduzieren (Attenuation).
- Rolle von Data Science: erhöht die Kapazität, Umweltkomplexität zu bewältigen.

### KOMPAKT ZUM LERNEN

- **Anpassung = eigene Varietät an die Umwelt angleichen.**
- Zu wenig Varietät → System wird von der Umwelt überfordert.
- Hebel: Varietät **erhöhen** (mehr Optionen) oder Umwelt **vereinfachen** (filtern).

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

„Big Data“, „Analytics“ und „Data Science“ werden im Alltag oft **synonym verwendet – das ist falsch**. Die Abgrenzung ist ein zentraler Prüfungspunkt.

**Big Data** beschreibt *Daten-Eigenschaften und Infrastruktur*: Volume, Variety, Velocity, Veracity (die „4 V“). Ein Datensatz ist nicht schon „big“, weil er gross ist, sondern wenn seine **Grösse/Komplexität zum eigentlichen Problem** wird. **Data Science** dagegen ist die deutlich *breitere Disziplin*: sie umfasst Methoden, Theorie und Anwendung und ist **transdisziplinär** (Mathematik, Statistik, Informatik/IT, Domänenwissen, Sozialwissenschaft). **Analytics** ist nur ein Teilaspekt davon (Auswertung/Modellierung).

Hilfreich zur Einordnung ist die **DIKIW-Hierarchie**: Data → Information → Knowledge → Intelligence → Wisdom. Data Science bewegt Rohdaten entlang dieser Kette hin zu Wissen und handlungsfähiger Intelligenz.

### DEFINITIONEN & BEGRIFFE

- **Big Data**: Daten, deren Volume/Variety/Velocity/Veracity besondere Verarbeitung erfordern; betrifft Daten & Infrastruktur.
- **Data Science**: transdisziplinäre Wissenschaft, die aus Daten Wissen/Handlung erzeugt (Methoden + Theorie + Anwendung).
- **Analytics**: die Auswertungs-/Modellierungs-Komponente innerhalb von Data Science.
- **DIKIW**: Data → Information → Knowledge → Intelligence → Wisdom.

### BEISPIEL

Ein Spital sammelt Millionen Sensor- und Patientendatensätze (**Big Data**, Infrastruktur-Frage). Ein **Data-Science-Team** formuliert das Problem, wählt Methoden, bezieht medizinisches Domänenwissen ein, berücksichtigt Ethik/Bias und erzeugt nutzbare Entscheidungen – das geht weit über reine Analytics hinaus.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- „Big Data = Data Science?“ → **Nein**. Big Data = Daten/Infrastruktur; Data Science = breite Disziplin.
- Die 4 V von Big Data nennen können (Volume, Variety, Velocity, Veracity).
- Data Science als **transdisziplinär** einordnen (vgl. Thema 30).
- DIKIW-Kette in richtiger Reihenfolge wiedergeben.

### KOMPAKT ZUM LERNEN

- **Big Data ≠ Data Science ≠ Analytics.**
- Big Data = Eigenschaften/Infrastruktur (4 V); Data Science = breite, transdisziplinäre Disziplin.
- Wertschöpfung entlang **DIKIW**.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

In einer **VUCA-Welt** (volatil, unsicher, komplex, mehrdeutig) versagen feste Modelle und starre Strategien. Gebraucht werden **adaptive, systemische und feedback-basierte** Entscheidungsmodelle, die sich *in Echtzeit* an neue Daten anpassen.

Technische Grundlage sind **Cyber-Physical Systems (CPS)**: Sensoren liefern kontinuierliche **Event-Streams** (Millisekunden bis Sekunden, „always on“), Software analysiert sie, und das System passt sein Verhalten über **Feedback-Loops** automatisch an (Control Optimization). Aus dem ML-Bereich passen besonders **Reinforcement Learning** (modellbasiert oder modellfrei – Lernen durch Belohnung/Bestrafung) und **Online-/Stream-Learning**. Der Gedanke des geschlossenen Regelkreises wird oft als *sense → think → act* bzw. PHAPI-Loop beschrieben: „Nur Organisationen, die in einem geschlossenen Loop wahrnehmen (Daten), denken (Modelle) und handeln (Policies), können bestehen.“

### DEFINITIONEN & BEGRIFFE

- **Adaptives Modell:** Modell, das sich aus laufendem Feedback fortlaufend anpasst, statt einmalig fix trainiert zu sein.
- **Event-Stream:** kontinuierlicher Strom von Sensor-/Statusdaten; Feedback ist schnell, kontinuierlich, datenreich.
- **Reinforcement Learning:** Agent lernt durch Trial-and-Error mit Reward/Penalty; *model-based* (lernt Umweltmodell, plant voraus) vs. *model-free* (lernt nur aus Reward-Historie).
- **Closed Loop (sense–think–act / PHAPI):** Daten → Insight → Aktion, fortlaufend zurückgekoppelt.

### BEISPIEL

Ein **Smart Thermostat** regelt die Heizung anhand von Echtzeit-Temperatur-Feedback. **Predictive Maintenance** in Turbinen erkennt Anomalien im Sensorstream und greift ein, bevor ein Ausfall passiert. Ein **RL-Agent** verbessert seine Aktionen Schritt für Schritt durch Belohnungssignale.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Warum versagen fixe Modelle in VUCA? → fehlende Anpassung an Volatilität/Komplexität.
- Eigenschaften von CPS-Feedback nennen: schnell, kontinuierlich, datenreich.
- Model-based vs. model-free RL unterscheiden.
- Closed-Loop-Idee erklären: sense → think → act.

#### KOMPAKT ZUM LERNEN

- VUCA → fixe Modelle reichen nicht → **adaptive, feedback-basierte** Modelle.
- Bausteine: CPS, Event-Streams, RL, Online-Learning, geschlossener Regelkreis.
- Merksatz: *sense (Daten)* → *think (Modelle)* → *act (Policies)*.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Overfitting** liegt vor, wenn ein Modell die Trainingsdaten *zu genau* lernt – inklusive Rauschen und Anomalien. Es bildet dann nicht die echte Beziehung ab, sondern „merkt sich“ die Daten. Folge: **sehr gute Trainingsleistung, aber schlechte Leistung auf neuen (Test-)Daten** → das Modell **generalisiert nicht** und ist wenig robust.

Das Gegenstück ist **Underfitting**: Das Modell ist *zu einfach*, erfasst die zugrundeliegenden Muster nicht und ist schon auf den Trainingsdaten schlecht (hoher Bias). Dazwischen liegt der gesuchte „**Sweet Spot**“ des **Bias-Variance-Tradeoffs**: ein gutes Modell balanciert beides aus – nicht zu viel Bias (Underfitting), nicht zu viel Varianz (Overfitting).

Eine versteckte Overfitting-Ursache ist **Data Leakage**: Wenn Test-/Zukunftsinformation ins Training „durchsickert“, wirkt das Modell im Training fälschlich gut, versagt aber real.

### DEFINITIONEN & BEGRIFFE

- **Overfitting**: Modell lernt Signal *und* Rauschen; top im Training, schwach im Test; kann nicht generalisieren.
- **Underfitting**: Modell zu simpel; schlecht im Training *und* Test; hoher Bias.
- **Bias-Variance-Tradeoff**: Spannung zwischen Bias (Underfitting) und Varianz (Overfitting); Ziel = Balance.
- **Generalisierung**: Fähigkeit, auf ungesehenen Daten gut zu funktionieren.

## ► ERKENNEN & GEGENSTEUERN

|                  | Trainingsfehler | Testfehler | Diagnose                    |
|------------------|-----------------|------------|-----------------------------|
| Underfitting     | hoch            | hoch       | Modell zu einfach (Bias)    |
| Gut (Sweet Spot) | niedrig         | niedrig    | balanciert                  |
| Overfitting      | sehr niedrig    | hoch       | Modell zu komplex (Varianz) |

Gegenmittel bei Overfitting: einfacheres Modell, mehr/saubere Daten, Regularisierung, korrekte **Cross-Validation**, und **Data Leakage vermeiden** (alle Feature-Schritte nur auf Trainingsdaten anwenden).

### BEISPIEL

Ein Modell erreicht 99 % Genauigkeit auf den Trainingsdaten, aber nur 70 % im Test – klassisches Overfitting: Es hat Eigenheiten/Rauschen der Trainingsdaten auswendig gelernt statt das echte Muster.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Overfitting vs. Underfitting an Train-/Testfehler erkennen (Tabelle!).
- Overfitting mit dem **Bias-Variance-Tradeoff** verbinden.
- Warum führt Data Leakage zu (scheinbar) gutem, real schlechtem Modell?
- Mindestens drei Gegenmassnahmen nennen.

### KOMPAKT ZUM LERNEN

- **Overfitting**: top im Training, schlecht im Test (zu komplex, lernt Rauschen).
- **Underfitting**: schlecht überall (zu einfach, hoher Bias).
- Ziel = **Balance** (Sweet Spot des Bias-Variance-Tradeoffs).

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Visualisierungen helfen, komplexe Modell-Ergebnisse verständlich zu machen und **Data Overload** zu bekämpfen (z. B. über Dashboards in Human-Centric-Anwendungen). Sie sind aber zweischneidig: **schlecht gestaltete oder missbrauchte Visualisierungen verzerren die Interpretation**, statt objektiv zu informieren.

Eine Visualisierung ist ein **Kommunikationsakt zwischen Sender und Empfänger** – und kann scheitern: Sie kann **Emotionen manipulieren** statt zu informieren, **mehrdeutig** sein, **falsche Vollständigkeit oder Logik** suggerieren und ist anfällig für (bewussten oder unbewussten) **Bias** in Design und Präsentation. Zudem erfordert das Lesen von Visualisierungen **Visual Literacy** – die Interpretation ist nicht immer intuitiv.

### DEFINITIONEN & BEGRIFFE

- **Visual Literacy:** Fähigkeit, Visualisierungen korrekt zu lesen und zu interpretieren.
- **Falsche Vollständigkeit:** Eine Grafik wirkt umfassend/logisch, obwohl sie selektiv ist.
- **Sender-Empfänger-Problem:** Was dargestellt wird (Sender) ≠ was verstanden wird (Empfänger).
- **True & Fair View:** Information muss *true* (sachlich korrekt) und *fair* (angemessen interpretierbar) dargestellt sein (vgl. Thema 19).

### BEISPIEL

Eine Balkengrafik mit abgeschnittener y-Achse lässt einen kleinen Unterschied riesig erscheinen – sie ist technisch „wahr“, aber nicht „fair“ und manipuliert die Wahrnehmung. Cherry-Picking von Datenpunkten erzeugt eine irreführende, scheinbar vollständige Aussage.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Fünf Fallstricke der Visualisierung nennen: Emotionsmanipulation, Mehrdeutigkeit, Visual-Literacy-Bedarf, falsche Vollständigkeit, Bias.
- Warum ist Visualisierung ein Kommunikationsproblem (Sender/Empfänger)?
- Bezug zu Transparenz/Trust & „True and Fair View“.
- Positiver Nutzen: Dashboards gegen Data Overload.

### KOMPAKT ZUM LERNEN

- Visualisierung = mächtig, aber **manipulierbar**.
- Risiken: Emotion, Mehrdeutigkeit, falsche Vollständigkeit, Bias, fehlende Visual Literacy.
- Massstab: **true & fair** – korrekt *und* angemessen interpretierbar.

### ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Komplexität entsteht durch **viele, voneinander abhängige Variablen**, bei denen Ursache und Wirkung nicht offensichtlich sind (vgl. das „C“ in VUCA). In der Data Science zeigt sich Komplexität besonders deutlich an den **Daten von Cyber-Physical Systems (CPS)**, die das Konzept der **Data Complexity** prägen. Diese Eigenschaften sind klassische „Komplexitäts-Beispiele“.

| Komplexitäts-Eigenschaft          | Beispiel                                                               |
|-----------------------------------|------------------------------------------------------------------------|
| Large Scale & High Dimensionality | Millionen von Sensoren mit vielen Messgrößen                           |
| Online & Real-Time Interaction    | fortlaufende physische Prozesse, sofortige Reaktion nötig              |
| Mixed Sources                     | Daten aus heterogenen Geräten/Plattformen                              |
| Strong Dynamics & High Frequency  | schnelle, kontinuierliche Updates                                      |
| Uncertainty & Noise               | Sensorfehler, Umgebungsschwankungen                                    |
| Unclear Structures / Hierarchies  | frühe oder sehr diverse Systeme ohne klare Struktur                    |
| Strong Sparsity                   | unvollständige/seltene Beobachtungen                                   |
| Heterogeneity                     | unterschiedliche Formate, Strukturen, Semantik                         |
| Non-IIDness                       | Abhängigkeiten über Zeit und Kontext (nicht unabhängig/gleichverteilt) |

#### DEFINITIONEN & BEGRIFFE

- **Komplexität:** viele interdependente Variablen; nicht-offensichtliche Ursache-Wirkung-Beziehungen.
- **Non-IIDness:** Daten sind *nicht* unabhängig und identisch verteilt – es bestehen zeitliche/kontextuelle Abhängigkeiten.
- **X-Complexities:** systemische Komplexitäten, die systemisches (nicht lineares) Denken verlangen.
- **„Mess“ vs. „Difficulty“:** komplexe, verflochtene Probleme (mess) statt einfacher, lösbarer Schwierigkeiten.

#### BEISPIEL

Eine **Smart City** oder ein **Connected Car**: heterogene Sensoren, hohe Frequenz, verrauschte Werte, zeitliche Abhängigkeiten, unklare Hierarchien – ein Paradebeispiel hochkomplexer, nicht-IID-Daten.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Mehrere konkrete Komplexitäts-Eigenschaften von CPS-Daten aufzählen können.
- **Non-IIDness** erklären (warum klassische Annahmen scheitern).
- Verbindung zu VUCA-„Complexity“ und zu Ashby (viel Umweltvarietät).
- Auswirkung: beeinträchtigt Wert, Qualität und Interpretierbarkeit der Daten.

### KOMPAKT ZUM LERNEN

- Komplexität = viele vernetzte Variablen, unklare Kausalität.
- CPS-Daten als Beispielkatalog: Scale, Real-Time, Mixed, Dynamics, Noise, Sparsity, Heterogeneity, Non-IID.
- Stichwort merken: **Non-IIDness**.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Class Weighting** ist eine Technik gegen **Class Imbalance** (ungleich verteilte Klassen, vgl. Thema 13). Dabei sagt man dem Algorithmus, er solle der **Minderheitsklasse beim Berechnen des Loss (Fehler) während des Trainings mehr Gewicht/Bedeutung geben**. So „kostet“ ein Fehler bei der seltenen Klasse mehr, und das Modell ignoriert sie nicht einfach zugunsten der Mehrheitsklasse.

Im Gegensatz zu **Sampling-Methoden** verändert Class Weighting *nicht die Daten*, sondern die **Verlustfunktion/Trainingslogik**. Das ist oft eleganter, weil keine Daten dupliziert oder gelöscht werden müssen.

| Methode                | Was passiert                                                                 |
|------------------------|------------------------------------------------------------------------------|
| Undersampling          | Mehrheitsklasse verkleinern (z. B. 800:100 → 100:100)                        |
| Oversampling           | Minderheitsklasse vergrößern durch Duplizieren (100 → 800)                   |
| SMOTE                  | neue, synthetische Minderheits-Samples durch Interpolation erzeugen          |
| <b>Class Weighting</b> | Minderheitsklasse im <b>Loss höher gewichtet</b> – Daten bleiben unverändert |

### DEFINITIONEN & BEGRIFFE

- **Class Weighting:** Gewichtung der Klassen in der Loss-Funktion, damit seltene Klassen stärker zählen.
- **Loss:** Mass für den Modellfehler, das beim Training minimiert wird.
- **Class Imbalance:** Klassen sind nicht in gleicher Menge vertreten.

### BEISPIEL

Bei **Fraud Detection** sind nur ~1 % der Transaktionen Betrug. Ohne Gewichtung würde ein Modell mit „immer kein Betrug“ 99 % Accuracy erzielen, aber jeden Betrug übersehen. Mit Class Weighting wird das Übersehen eines Betrugsfalls im Training teuer bestraft.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Class Weighting von Over-/Undersampling und SMOTE abgrenzen (verändert Loss, nicht Daten).
- Warum hilft es gegen irreführende Accuracy bei Imbalance?
- Wann ist es vorteilhaft? (keine Datenmanipulation nötig).

#### KOMPAKT ZUM LERNEN

- **Class Weighting = Minderheitsklasse im Loss höher gewichten.**
- Alternative zu Sampling – verändert *nicht* die Daten.
- Verhindert, dass die Mehrheitsklasse das Modell dominiert.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Zielorientiertes Handeln** bedeutet, ein Data-Science-Projekt konsequent vom **Ziel (Target) her** zu denken und zu steuern – und am Ende des Erkenntniszyklus tatsächlich zu **handeln**. Statt mit Daten/Tools zu starten, fragt man zuerst: „*Welches Problem wollen wir lösen? Welches Ergebnis brauchen wir?*“ Alles Weitere (Daten, Features, Methoden, Metriken) wird um dieses Ziel herum gestaltet.

Der Bezug zur Aktion ist zentral: Im **geschlossenen Entscheidungszyklus (PHAPI: sense → think → act)** ist die **Handlung/Policy** der eigentliche Zweck. Data Science soll komplexe Probleme in *quantitatives, handlungsfähiges Wissen* übersetzen – also in Dinge, die man messen, verstehen und in Aktion umsetzen kann. Ziele müssen daher **messbar** sein und alle Stakeholder müssen auf dasselbe Ziel ausgerichtet sein.

### DEFINITIONEN & BEGRIFFE

- **Target-Oriented / Target-Centric Action:** Handeln, das vom definierten Ziel her geplant und auf eine konkrete Aktion ausgerichtet ist.
- **Actionable Knowledge:** Wissen, das messbar und direkt in Entscheidungen/Handlungen umsetzbar ist.
- **PHAPI / Closed Loop:** Daten → Insight → **Aktion**, rückgekoppelt.
- **Messbares Ziel:** klar & quantifizierbar, z. B. „Churn in 3 Monaten um 10 % senken“.

### BEISPIEL

**Data-first (falsch):** „Wir haben diese Daten – was können wir damit machen?“ **Target-oriented (richtig):** „Wir wollen verspätete Lieferungen reduzieren – welche Daten brauchen wir dafür und welche Massnahme leiten wir ab?“

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Unterschied „data-first“ vs. „target-oriented“ erklären.
- Warum scheitern Projekte ohne klares Ziel? (Fokusverlust, „playing with data“).
- Bezug zum Closed Loop: Ziel → Insight → **Aktion**.
- Merkmal nennen: Ziele **messbar** machen, Stakeholder ausrichten.

### KOMPAKT ZUM LERNEN

- **Erst das Ziel, dann alles andere** – und am Ende eine konkrete Aktion.
- Ziel = messbar; Stakeholder = ausgerichtet.
- Data Science erzeugt **actionable knowledge** (sense → think → act).

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Explainable AI (XAI)** umfasst Techniken und Methoden, um zu verstehen, **warum** eine KI eine bestimmte Entscheidung trifft. Das Wissen über die Gründe einer Entscheidung gilt als Schlüssel, um Modellentscheidungen nachzuvollziehen und das **Vertrauen der Nutzer** in KI-Lösungen zu erhöhen.

Gute Erklärungen sind **interaktiv** (Nutzer können „warum“ und „wie“ explorieren) und **nutzerspezifisch** (angepasst an Wissensstand – Data Scientist vs. Entscheider). XAI ist damit essenziell für **Transparenz, Vertrauen und ethischen Einsatz**. Eine wichtige Herausforderung: Moderne **Foundation Models** sind durch ihre Grösse und Komplexität schwer interpretierbar (riesige Parameterräume, intransparente Interaktionen). XAI fokussiert oft auf technische Faktoren (Skalierbarkeit, Output-Klarheit) und vernachlässigt die **menschlichen kognitiven Prozesse** – echte Interpretierbarkeit bleibt eine offene Aufgabe.

### DEFINITIONEN & BEGRIFFE

- **XAI (Explainable AI):** Methoden, die KI-Entscheidungen verständlich machen.
- **Transparenz:** Offenheit/Verständlichkeit der Modelllogik.
- **Traceability:** Nachvollziehbarkeit/Auditierbarkeit von Logik und Ergebnissen.
- **Interpretability:** Grad, in dem ein Mensch die Modellentscheidung nachvollziehen kann.

### BEISPIEL

Ein Kredit-Scoring-Modell lehnt einen Antrag ab. XAI zeigt: „Ablehnung v. a. wegen kurzer Kredithistorie und hoher bestehender Schulden.“ Der/die Sachbearbeiter:in versteht die Entscheidung, kann sie prüfen und ggf. korrigieren (Bezug zu HITL).

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Definition XAI und **warum** es wichtig ist (Trust, Transparenz, Ethik).
- Eigenschaften guter Erklärungen: **interaktiv** und **nutzerspezifisch**.
- Warum sind grosse/Foundation-Modelle schwer erklärbar?
- Bezug zu OECD/UN-Prinzipien (Explainability über den ganzen Lebenszyklus) und zu Transparency & Trust.

### KOMPAKT ZUM LERNEN

- **XAI = „Warum entscheidet die KI so?“** → Schlüssel zu Vertrauen.
- Gut = interaktiv + nutzerspezifisch.
- Herausforderung: grosse Modelle sind schwer interpretierbar; menschliche Kognition wird oft übersehen.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Bei der **Steuerung (Control)** komplexer Systeme – besonders bei **Cyber-Physical Systems (CPS)** – ist **Ashbys Gesetz der erforderlichen Varietät** die theoretische Grundlage: *Ein Controller muss die Varietät des Systems erreichen/abbilden, um es effektiv steuern zu können*. Reicht die Varietät des Reglers nicht aus, lässt sich das System nicht beherrschen.

CPS-Control verbindet reale Prozesse (Maschinen, Produktionslinien, Personenflüsse) über **Feedback, Modelle und intelligente Steuerungsmechanismen** mit digitaler Entscheidungsfindung. Sie wurzelt in **Kybernetik und Systemtheorie**. Zentral ist **modellbasierte Steuerung**: hochwertige Modelle sind nötig, um Verhalten zu verstehen und gute Entscheidungen zu treffen. Da CPS hohe Varietät erzeugen, ist das „Matching“ von Reglervarietät und Systemvarietät die Kernherausforderung.

### DEFINITIONEN & BEGRIFFE

- **Ashbys Law (Control-Sicht):** Der Controller muss mindestens so viel Varietät besitzen wie das zu steuernde System.
- **Kybernetik:** Lehre vom Steuern/Regeln über Feedback, Kommunikation und Modellierung.
- **Modellbasierte Steuerung:** Steuerung auf Basis genauer Systemmodelle.
- **CEP / SPC:** Complex Event Processing (Muster in Datenströmen) bzw. Statistical Process Control (Prozessabweichungen) als Cyber-Layer-Funktionen.

### BEISPIEL

Eine **Manufacturing-Execution-System (MES)**-Steuerung muss auf die Vielfalt möglicher Maschinen-/Prozesszustände vorbereitet sein. Nur wenn die Steuerungslogik (Regler) genügend Varietät hat (genug Zustände erkennt und passend reagiert), bleibt die Produktion stabil – ganz im Sinne von Ashby.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Ashbys Gesetz in der Control-Variante formulieren:  $\text{Reglervarietät} \geq \text{Systemvarietät}$ .
- Welche Theorien fundieren CPS-Control? (Kybernetik, Systemtheorie, Ashby).
- Warum ist modellbasierte Steuerung nötig?
- Cyber-Layer-Funktionen nennen: CEP, SPC, Datenintegration.

### KOMPAKT ZUM LERNEN

- **Steuerung gelingt nur, wenn der Regler genug Varietät hat (Ashby).**
- Grundlage: Kybernetik + Systemtheorie + modellbasierte Steuerung.
- CPS-Werkzeuge: Feedback-Loops, CEP, SPC.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Das **Viable System Model (VSM)** ist eine **rekursive Management-Struktur für komplexe Systeme**.

„Viable“ (lebensfähig) heisst: Das System kann in einer veränderlichen Umwelt eigenständig überleben und sich anpassen. Es wurzelt in der **Kybernetik** (Stafford Beer).

Kennzeichnend ist die **Rekursivität**: Jedes lebensfähige System enthält selbst wieder lebensfähige Teilsysteme, die nach demselben Muster aufgebaut sind und sich gegenseitig überwachen und regulieren. Das VSM enthält **anti-oszillatorische Feedback-Loops**, die **Anpassungsfähigkeit, Lernen und Systemgesundheit** sicherstellen – also verhindern, dass das System in Schwingungen/Instabilität gerät. Damit lässt sich das VSM gut auf **mehrstufige CPS** abbilden, in denen verschiedene Subsysteme einander überwachen und regeln.

### DEFINITIONEN & BEGRIFFE

- **VSM**: rekursives Management-/Organisationsmodell, das die Lebensfähigkeit komplexer Systeme sichert.
- **Viable / Lebensfähigkeit**: Fähigkeit eines Systems, eigenständig zu überleben und sich anzupassen.
- **Rekursion**: gleiche Struktur auf mehreren Ebenen ineinander verschachtelt.
- **Anti-oszillatorische Feedback-Loops**: Rückkopplungen, die Schwingungen dämpfen und Stabilität/Lernen sichern.

### BEISPIEL

Ein Konzern als VSM: Gesamtunternehmen, Sparten und Teams sind jeweils nach demselben Steuerungsmuster aufgebaut. Jede Ebene reguliert sich weitgehend selbst; übergeordnete Ebenen greifen über Feedback nur ein, wenn Instabilität droht. Analog in einem mehrschichtigen CPS (Sensor → Maschine → Linie → Werk).

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- VSM definieren: **rekursive Management-Struktur** für Lebensfähigkeit.
- Wofür dienen die anti-oszillatorischen Feedback-Loops? (Anpassung, Lernen, Stabilität).
- Warum passt VSM gut zu mehrstufigen CPS?
- Abgrenzung zu System Dynamics (Struktur vs. Simulation – vgl. Thema 1).

### KOMPAKT ZUM LERNEN

- **VSM = rekursive Struktur für lebensfähige, sich selbst regulierende Systeme.**
- Anti-oszillatorische Feedback-Loops → Anpassung, Lernen, Gesundheit.
- Gut abbildbar auf mehrstufige CPS.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Class Imbalance** liegt vor, wenn die Datenpunkte pro Klasse **nicht in gleicher Menge** vorhanden sind – bestimmte Klassen sind also stark unterrepräsentiert. Das ist gefährlich, weil es zu **irreführender Accuracy** führt: Ein Modell kann einfach immer die Mehrheitsklasse vorhersagen und trotzdem hohe Genauigkeit erzielen, während die **Minderheitsklasse ignoriert** wird – genau die ist aber oft die wichtige (z. B. Betrug, seltene Krankheit).

## ► LÖSUNGEN

| Lösung          | Prinzip                                                                           |
|-----------------|-----------------------------------------------------------------------------------|
| Undersampling   | Mehrheitsklasse verkleinern (800:100 → 100:100)                                   |
| Oversampling    | Minderheitsklasse durch Duplizieren vergrößern (100 → 800)                        |
| SMOTE           | synthetische Minderheits-Samples durch Interpolation erzeugen (statt Duplizieren) |
| Class Weighting | Minderheitsklasse im Loss höher gewichten (vgl. Thema 8)                          |

### DEFINITIONEN & BEGRIFFE

- **Class Imbalance:** ungleiche Anzahl Datenpunkte pro Klasse.
- **Irreführende Accuracy:** hohe Gesamtgenauigkeit trotz Versagen bei der wichtigen Klasse.
- **SMOTE:** Synthetic Minority Over-sampling Technique – interpoliert neue Samples zwischen bestehenden.

### BEISPIEL

**Fraud Detection** oder **seltene Krankheiten:** Die interessante Klasse macht nur wenige Prozent aus. Accuracy ist hier ein schlechtes Mass – besser sind Precision/Recall/F1 (vgl. Thema 19).

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Definition Class Imbalance und warum Accuracy täuscht.
- Vier Lösungen nennen (Under-, Oversampling, SMOTE, Class Weighting).
- Unterschied SMOTE vs. einfaches Oversampling (synthetisch vs. dupliziert).
- Typische Anwendungsfälle nennen.

#### KOMPAKT ZUM LERNEN

- **Imbalance** → **Accuracy trügt, Minderheit wird ignoriert.**
- Daten-Lösungen: Under-/Oversampling, SMOTE. Algorithmus-Lösung: Class Weighting.
- Beispiele merken: Fraud, seltene Krankheiten.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Uncertainty (Unsicherheit)** ist eine der vier VUCA-Dimensionen. Sie beschreibt Situationen, in denen die **zukünftigen Ergebnisse unbekannt sind – obwohl Daten vorhanden sind**. Man hat also Informationen, aber keine verlässliche Vorhersagbarkeit. Wichtig: Unsicherheit ist *nicht* dasselbe wie Komplexität (viele vernetzte Variablen) oder Volatilität (schnelle, instabile Veränderung) – sie wird in der Prüfung gerne verwechselt.

Traditionelle Entscheidungsfindung versagt unter Unsicherheit häufig. Data Science liefert Werkzeuge, um trotz begrenzter Vorhersagbarkeit zu **sense, model und respond** (wahrnehmen, modellieren, reagieren) und **evidenzbasiert** zu handeln. Hilfreich sind **System Dynamics** (Feedback-Loops, Delays sichtbar machen) und **Szenario-Denken**.

### DEFINITIONEN & BEGRIFFE

- **Uncertainty:** Zukunft trotz vorhandener Daten unbekannt/nicht verlässlich vorhersagbar.
- **Abgrenzung:** Volatility = instabil, nicht zwingend komplex; Complexity = viele Variablen; Ambiguity = unklare Bedeutung/keine Präzedenzfälle.
- **Evidence-based action:** Handeln gestützt auf Daten/Modelle statt Bauchgefühl.

### BEISPIEL

Eine **Konkurrenzreaktion**: Man kennt Markt- und Wettbewerbsdaten, aber weiss nicht, wie der Konkurrent auf die eigene Preissenkung reagiert. Daten sind da, das Ergebnis bleibt unsicher → Szenarien durchspielen statt einer fixen Prognose vertrauen.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Uncertainty sauber von Volatility, Complexity, Ambiguity abgrenzen (häufige Verwechslung!).
- Warum reichen klassische Methoden nicht? Rolle von Data Science (sense–model–respond).
- Beispiel für Unsicherheit geben können.
- Bezug: jede VUCA-Dimension braucht einen *eigenen* Ansatz (vgl. Thema 25/Misconceptions).

### KOMPAKT ZUM LERNEN

- **Uncertainty = Daten da, Zukunft trotzdem unbekannt.**
- Nicht verwechseln mit Volatility/Complexity/Ambiguity.
- Antwort: sense → model → respond, evidenzbasiert, Szenarien.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Unsupervised Learning** arbeitet mit **unlabelten Daten** – es gibt keine vorgegebenen „richtigen Antworten“. Der Algorithmus muss selbst **verborgene Muster, Gruppierungen oder Strukturen** entdecken. Man gibt dem Computer also rohe Daten ohne Kategorien, und er findet eigenständig heraus, was zusammengehört.

Typische Aufgaben sind **Clustering** (ähnliche Dinge gruppieren) und **Pattern Discovery** (verborgene Strukturen finden). Im Gegensatz zum Supervised Learning braucht es **keine Labels** – das macht die Daten billiger –, aber die Ergebnisse sind **schwerer zu evaluieren**, weil es keine „korrekte Antwort“ gibt. Unsupervised Learning eignet sich hervorragend für **Exploration**.

### DEFINITIONEN & BEGRIFFE

- **Unsupervised Learning:** Lernen aus unlabelten Daten; Ziel = Muster/Gruppen entdecken.
- **Clustering:** Zusammenfassen ähnlicher Datenpunkte zu Gruppen.
- **Pattern Discovery:** Auffinden verborgener Strukturen.
- **Algorithmen:** K-Means, K-Medoids, Fuzzy C-Means (vgl. Thema 20).

### BEISPIEL

Man gibt dem Computer Einkaufsdaten von Kunden *ohne* Kategorien. Das Modell erkennt: „Diese Personen kaufen Ähnliches – sie könnten eine Gruppe sein.“ → Kundensegmentierung ohne vorgegebene Labels.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Definition + Abgrenzung zu Supervised (keine Labels vs. Labels).
- Typische Aufgaben: Clustering, Pattern Discovery.
- Vor-/Nachteile: billigere Daten, aber schwer zu evaluieren.
- Algorithmen nennen können (K-Means etc.).

### KOMPAKT ZUM LERNEN

- **Keine Labels** → **Muster/Gruppen selbst finden.**
- Aufgaben: Clustering & Pattern Discovery.
- Billige Daten, aber Bewertung schwierig; ideal zur Exploration.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Ashbys Law of Requisite Variety** ist das zentrale Gesetz der Kybernetik in diesem Kurs. Es besagt: „*When the variety or complexity of the environment exceeds the capacity of a system (natural or artificial), the environment will dominate and ultimately destroy that system.*“ Anders formuliert: Um ein System zu beherrschen, braucht ein Controller **mindestens so viel Varietät wie das System selbst** – „only variety can absorb variety“.

Varietät ist dabei das **Mass für Komplexität** (Anzahl unterscheidbarer Zustände). Hat ein System zu wenig Varietät gegenüber seiner Umwelt, kommt es zu „**fatal undercomplexity**“ – die Steuerungsmechanismen reichen nicht aus, das System wird überfordert. Dieses Gesetz verbindet die Themen 2 (Adaptation), 11 (Control) und 25 (Misinterpretation).

### DEFINITIONEN & BEGRIFFE

- **Requisite Variety:** die zur Steuerung erforderliche Mindest-Varietät des Controllers.
- **Varietät:** Anzahl unterscheidbarer Zustände = Komplexitätsmass.
- **Fatal undercomplexity:** Zustand, in dem die eigenen Steuerungsmechanismen der Umweltkomplexität nicht gewachsen sind.
- **Kybernetik:** Wissenschaft von Steuerung/Regelung über Feedback.

### BEISPIEL

Ein simples, regelbasiertes IT-System soll einen hochdynamischen Markt steuern. Da die Marktvarietät die Systemvarietät übersteigt, „dominiert“ der Markt – das System reagiert ständig falsch oder zu spät. Erst mehr Varietät (adaptive Modelle, mehr Datenquellen) stellt die Steuerbarkeit wieder her.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Das Gesetz wörtlich/sinngemäß wiedergeben können.
- „only variety can absorb variety“ erklären.
- Begriff **fatal undercomplexity** einordnen.
- Verbindung zu VUCA Role Limits: traditionelle Systeme stossen an Grenzen, wenn Umweltvarietät ihre Kapazität übersteigt.

### KOMPAKT ZUM LERNEN

- **Nur Varietät kann Varietät absorbieren.**
- Umweltkomplexität > Systemkapazität → Umwelt dominiert/zerstört System.
- Zu wenig Varietät = **fatal undercomplexity**.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**System Dynamics** ist eine **simulationsbasierte Methodik**, die **qualitative Einsichten mit quantitativer Modellierung** verbindet. Sie untersucht, *warum* sich Systeme über die Zeit so verhalten, wie sie es tun – mit Fokus auf Wechselwirkungen statt Einzelteilen.

Kernbausteine sind: **Feedback-Loops** – *balancing/negativ* („je mehr A, desto weniger B“) und *reinforcing/positiv* („je mehr A, desto mehr B“); **Delays** (Zeitverzögerungen, die das Verhalten verändern); **Stocks & Flows** (Bestände vs. Änderungsraten); und **Nichtlinearität** (reale Ursache-Wirkung ist selten linear). Modelliert wird mit **Causal Loop Diagrams** und **Stock-Flow Diagrams**, z. B. in **Vensim/STELLA**.

### DEFINITIONEN & BEGRIFFE

- **Balancing Loop:** stabilisierende, negative Rückkopplung.
- **Reinforcing Loop:** verstärkende, positive Rückkopplung.
- **Stock / Flow:** Akkumulation (Lager) vs. Änderungsrate (Verkäufe/Tag).
- **Causal Loop Diagram (CLD):** Diagramm der Ursache-Wirkungs-Schleifen.

### BEISPIEL

**Bullwhip-Effekt** in Lieferketten: kleine Nachfrageschwankungen schaukeln sich durch Delays und Feedback zu grossen Bestellschwankungen auf. Weitere Anwendungen: Verkehrsfluss/Stau, nachhaltiges Ressourcenmanagement, organisationale Anpassung in VUCA.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Vier Bausteine nennen: Feedback-Loops, Delays, Stocks & Flows, Nichtlinearität.
- Balancing vs. reinforcing loop unterscheiden (mit „je mehr A...“-Formel).
- Werkzeuge/Software nennen: CLD, Stock-Flow, Vensim.
- Anwendungsbeispiel (Bullwhip) erklären; Abgrenzung zu VSM (Thema 1).

### KOMPAKT ZUM LERNEN

- **SD = Simulation des Verhaltens über Zeit** (qualitativ + quantitativ).
- Bausteine: Feedback-Loops (balancing/reinforcing), Delays, Stocks & Flows, Nichtlinearität.
- Tools: CLD, Stock-Flow-Diagramme, Vensim/STELLA.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Die **Smart Factory** (vernetzte/digitale Fabrik) ist eine zentrale Anwendung von **Cyber-Physical Systems (CPS)** und das Herzstück von **Industrie 4.0**. Physische Produktionsmaschinen werden eng mit der Cyber-Ebene (Datenverarbeitung, Steuerung, IT) verknüpft, um **Echtzeit-Monitoring, -Steuerung und -Optimierung** der Produktion zu ermöglichen.

Ein typisches Beispiel sind **Manufacturing Execution Systems (MES)**: Sie verbinden Produktionsmaschinen (physisch) mit ERP-Systemen (cyber) und erlauben so durchgängige Überwachung und Optimierung. Data Science liefert dazu **Predictive Maintenance** (Ausfälle vorhersagen), **Anomaly Detection** (ungewöhnliche Sensorwerte), **Control Optimization** und **Stream Data Processing**. Die Steuerung folgt dabei kybernetischen Prinzipien (Feedback-Loops, Ashby – vgl. Themen 11/16).

### DEFINITIONEN & BEGRIFFE

- **Smart Factory**: CPS-basierte, vernetzte Produktion mit Echtzeit-Steuerung (Industrie 4.0).
- **MES**: Manufacturing Execution System – Brücke zwischen Maschine (physisch) und ERP (cyber).
- **Predictive Maintenance**: datenbasierte Vorhersage von Ausfällen, bevor sie eintreten.
- **Edge Intelligence**: Intelligenz nahe an den Sensoren/Maschinen.

### BEISPIEL

In einer Fertigungslinie meldet ein Vibrationssensor steigende Werte; das System erkennt das Muster (Anomaly Detection), prognostiziert einen Lagerschaden (Predictive Maintenance) und plant die Wartung ein, bevor die Maschine ausfällt – alles in einem geschlossenen Feedback-Loop.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Smart Factory als CPS-Anwendung einordnen (physisch + cyber + Vernetzung).
- MES erklären und als CPS-Beispiel nennen.
- Rolle von Data Science: Predictive Analytics, Anomaly Detection, Control Optimization, Stream Processing.
- Bezug zu Industrie 4.0 / Smart Cities / Autonomous Vehicles als weitere CPS-Felder.

### KOMPAKT ZUM LERNEN

- **Smart Factory = CPS in der Produktion (Industrie 4.0).**
- MES verbindet Maschine ↔ ERP; Echtzeit-Monitoring/Steuerung/Optimierung.
- Data-Science-Beitrag: Predictive Maintenance, Anomaly Detection, Stream Processing.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Die **Modell-Evaluation** prüft, wie gut ein Modell mit der **Ground Truth** übereinstimmt. **Evaluationsmetriken** übersetzen Geschäfts-/Forschungsziele in **konkrete, messbare Zahlen**, die zeigen, ob ein Modell Wert liefert. In **CRISP-DM** ist Evaluation die Testphase, die an einem vordefinierten Design ausgerichtet ist und auch Experten-Feedback einbezieht.

Die bekannteste Metrik ist **Accuracy** – sie ist aber bei **Class Imbalance** irreführend (vgl. Thema 13). Dann nutzt man **Precision, Recall, F1** sowie Werkzeuge wie **Confusion Matrix** und **ROC-Kurve**. Ein robuster Evaluationsplan reicht von der Zielformulierung über den Modellvergleich bis zum **Deployment-Monitoring** und umfasst auch **Data-Quality-Metriken** (Vollständigkeit, Genauigkeit, Validität, Aktualität, Eindeutigkeit, Konsistenz).

### DEFINITIONEN & BEGRIFFE

- **Accuracy:** Anteil korrekter Vorhersagen – bei Imbalance unzuverlässig.
- **Confusion Matrix:** Tabelle aus TP/FP/TN/FN, Basis vieler Metriken.
- **Precision / Recall / F1:** Genauigkeit der Positiv-Vorhersagen / Trefferquote / harmonisches Mittel beider.
- **ROC-Kurve:** Trade-off zwischen Trefferrate und Falschalarmen.
- **Ground Truth:** die tatsächlichen, korrekten Werte als Vergleichsmassstab.

### BEISPIEL

Ein Betrugsmodell hat 99 % Accuracy, aber Recall = 0 % (es findet keinen einzigen Betrug). Erst Precision/Recall/F1 und die Confusion Matrix decken auf, dass das Modell trotz hoher Accuracy wertlos ist.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Warum ist Accuracy bei Imbalance irreführend? Welche Metriken stattdessen?
- Confusion Matrix und ROC erklären können.
- Evaluation in CRISP-DM einordnen (Testphase, Experten-Feedback).
- Evaluationsplan über mehrere Ebenen: Ziel → Modellvergleich → Deployment-Monitoring; plus Data-Quality-Metriken.

### KOMPAKT ZUM LERNEN

- **Metriken = Ziele in messbare Zahlen übersetzen.**
- Accuracy täuscht bei Imbalance → Precision/Recall/F1, Confusion Matrix, ROC.
- Evaluation = ganzer Plan (Ziel → Vergleich → Monitoring) + Datenqualität.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Während Thema 15 das Prinzip des unüberwachten Lernens erklärt, geht es hier um die **konkreten Algorithmen**. Sie suchen ohne Labels nach **Gruppen/Clustern** in den Daten. Die im Kurs genannten Hauptvertreter sind **K-Means, K-Medoids und Fuzzy C-Means**; dazu kommen weitere analytische Modelle wie **Self-Organizing Maps** und **Association**.

| Algorithmus   | Kurzprinzip                                                                                            |
|---------------|--------------------------------------------------------------------------------------------------------|
| K-Means       | teilt Daten in k Cluster; jeder Punkt gehört zum nächstgelegenen Cluster- <i>Mittelwert</i> (Centroid) |
| K-Medoids     | wie K-Means, aber Cluster-Zentrum ist ein reales Datenobjekt (Medoid) → robuster gegen Ausreisser      |
| Fuzzy C-Means | „weiches“ Clustering: ein Punkt kann mit Zugehörigkeitsgrad zu <i>mehreren</i> Clustern gehören        |

### DEFINITIONEN & BEGRIFFE

- **Centroid:** Mittelpunkt eines Clusters (K-Means).
- **Medoid:** repräsentatives reales Datenobjekt als Cluster-Zentrum (K-Medoids).
- **Fuzzy / Soft Clustering:** Teil-Zugehörigkeit zu mehreren Clustern statt harter Zuordnung.
- **k:** vorab gewählte Anzahl Cluster.

### BEISPIEL

Kundensegmentierung: **K-Means** bildet z. B. 3 Kundengruppen anhand des Kaufverhaltens. Gibt es starke Ausreisser, ist **K-Medoids** stabiler. Wenn Kunden zu mehreren Gruppen passen, liefert **Fuzzy C-Means** Zugehörigkeitsgrade.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Die drei Algorithmen nennen und unterscheiden (Centroid vs. Medoid vs. fuzzy).
- Warum ist K-Medoids robuster gegen Ausreisser?
- Was bedeutet „soft“ bei Fuzzy C-Means?
- Einordnung als Clustering-/unsupervised-Verfahren (Bezug Thema 15 & 22).

### KOMPAKT ZUM LERNEN

- **K-Means** = Centroid, **K-Medoids** = reales Objekt (robust), **Fuzzy C-Means** = Mehrfachzugehörigkeit.
- Alle sind Clustering-Verfahren ohne Labels.
- k = Anzahl Cluster wird vorgegeben.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Der **Target-Centric Approach** ist eine **strukturierte, iterative Methode** zum Sammeln und Analysieren von Informationen, um Entscheidungen zu verbessern. Im Gegensatz zu linearen Modellen **verfeinert er die Erkenntnisse kontinuierlich**, sobald neue Daten verfügbar werden – die Analyse ist also dynamisch und anpassbar. (Inhaltlich identisch mit „Target-Centric Framing“, vgl. Thema 9.)

Als **Strategie** bedeutet er die **Ausrichtung von Aktivitäten, Technologien und Daten auf konkrete Geschäftsziele, Subjekte oder Stakeholder-Bedürfnisse**. Statt generisch oder system-zentriert vorzugehen, setzt man einen klaren Fokus (Unternehmensziele, Kundennutzen, strategische Prioritäten), um Handlungen zu lenken, Ressourcen optimal zu nutzen und messbare Ergebnisse zu erzielen.

### DEFINITIONEN & BEGRIFFE

- **Goal orientation:** Aktivitäten sind um strategische Ziele herum strukturiert.
- **Subject orientation:** Systeme (z. B. Data Warehouse) werden um Geschäftsobjekte (Kunde, Produkt) organisiert.
- **Customer focus:** Analyse/Entscheidung zentriert auf Kundenbedürfnisse & Profitabilität.
- **Priority setting:** Ressourcen werden nach klaren, strategieabgeleiteten Prioritäten verteilt.

### BEISPIEL

Eine „**Customer 360**“-Sicht vereint Daten aus vielen Systemen, um strategische Kundeneinblicke zu gewinnen. BI-Systeme werden so gebaut, dass sie Unternehmensziele direkt unterstützen; Data-Lineage konzentriert sich nur auf geschäftskritische Datenflüsse.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Definition: strukturiert, iterativ, nicht linear, verfeinert laufend.
- Vier Kern-Charakteristika: goal-, subject-, customer-orientation, priority setting.
- Abgrenzung zu data-first / system-centric (vgl. Thema 9).
- Warum es zählt: Effizienz, zielgerichtete Entscheidungen, Accountability, Agilität.

### KOMPAKT ZUM LERNEN

- **Alles um das Ziel/Subjekt herum ausrichten – iterativ verfeinern.**
- 4 Merkmale: goal, subject, customer, priority.
- = Target-Centric Framing (Thema 9), nur stärker strategisch.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Clustering** ist ein unüberwachtes Verfahren, das **ähnliche Datenpunkte zu Gruppen** zusammenfasst (vgl. Themen 15/20). Es beantwortet die Frage „Welche Objekte gehören zusammen?“ anhand von Ähnlichkeit/Distanz.

**Network Analysis** betrachtet dagegen die **Beziehungen und Verbindungen** zwischen Objekten. Im Kurs ist „Network“ eine eigene **Quelle von Intelligenz** (Informationen aus Kommunikation, Verbindungen, Systemen), und im „Data DNA“-Framework sind **Relationships** ein Grundbaustein neben Entities und Properties. Während Clustering Gruppen *bildet*, deckt Netzwerkanalyse *Strukturen von Verbindungen* auf (z. B. wer mit wem, welche Knoten sind zentral). Beide ergänzen sich: Cluster können Communities in einem Netzwerk sein.

### DEFINITIONEN & BEGRIFFE

- **Clustering:** Gruppieren ähnlicher Punkte (distanz-/ähnlichkeitsbasiert), ohne Labels.
- **Network Analysis:** Analyse von Knoten (Entities) und Kanten (Relationships) in einem Netzwerk.
- **Data DNA – Relationships:** Verbindungen/Assoziationen zwischen Entities und ihren Properties.
- **Community:** dicht verbundener Teilbereich eines Netzwerks ( $\approx$  Cluster im Graphen).

### BEISPIEL

**Clustering:** Kunden nach Kaufverhalten gruppieren. **Network Analysis:** in einem sozialen Netzwerk erkennen, welche Personen einflussreich sind (zentrale Knoten) und welche Gruppen eng vernetzt sind (Communities) – etwa zur Betrugs- oder Influencer-Erkennung.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Clustering vs. Network Analysis abgrenzen: Gruppen bilden vs. Verbindungen analysieren.
- Bezug zu unsupervised learning (Clustering) herstellen.
- „Network“ als Intelligenz-Quelle und „Relationships“ in der Data DNA einordnen.
- Wie ergänzen sich beide? (Cluster = Communities im Netzwerk).

### KOMPAKT ZUM LERNEN

- **Clustering = Gruppen anhand Ähnlichkeit.**
- **Network Analysis = Struktur der Verbindungen** (Knoten & Kanten).
- Beide unüberwacht/explorativ; ergänzen sich (Communities  $\approx$  Cluster).

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

„Big Data“ und „Data Science“ sind **Buzzwords**, umgeben von Hype und Missverständnissen. Das führt zu Verwirrung, überzogenen Erwartungen und fehlendem Konsens über die eigentliche Bedeutung. Die wichtigsten Mythen solltest du benennen und widerlegen können:

| Mythos                                   | Richtigstellung                                                                                 |
|------------------------------------------|-------------------------------------------------------------------------------------------------|
| Big Data dreht sich nur um Volume        | Komplexität ist oft entscheidender als Grösse                                                   |
| Big Data = Data Science / Analytics      | Big Data = Daten/Infrastruktur; Data Science = breite Disziplin (vgl. Thema 3)                  |
| Man braucht riesige Infrastruktur        | auch kleine Skalen & methodische Arbeit sind sinnvoll                                           |
| Mehr Daten sind immer besser             | Relevanz & Qualität schlagen schiere Menge                                                      |
| Datenqualität ist unwichtig              | <b>Veracity</b> ist essenziell; viel + schlecht = unzuverlässig/schädlich                       |
| Fokus auf strukturierte/prädiktive Daten | ~95 % der Big Data sind <b>unstrukturiert</b> (Text, Audio, Bild)                               |
| Single Version of Truth (SSOT)           | realistischer ist oft MVOT (Multiple Versions of the Truth); kein automatischer „Golden Record“ |
| Data Lakes sind per se wertvoll          | ohne Metadaten werden sie zu <b>Data Swamps</b>                                                 |

### DEFINITIONEN & BEGRIFFE

- **Veracity:** Verlässlichkeit/Vertrauenswürdigkeit der Daten (eine der Big-Data-V's).
- **SSOT vs. MVOT:** eine vs. mehrere legitime „Wahrheiten“ je nach Kontext.
- **Data Swamp:** unbrauchbar gewordener Data Lake ohne Metadaten/Governance.
- **Spurious Correlation:** Scheinkorrelation in grossen Datensätzen → falsche Schlüsse.

### BEISPIEL

Ein Unternehmen kippt alle Rohdaten in einen Data Lake, ohne Metadaten zu pflegen. Niemand findet mehr etwas wieder – aus dem See wird ein **Swamp**. Oder: In riesigen Datenmengen findet man eine starke, aber sinnlose Korrelation (spurious) und zieht falsche Schlüsse.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Mehrere Big-Data-Mythen nennen und widerlegen.
- „Mehr Daten = besser?“ → nein, Relevanz/Qualität zählt.
- Begriffe MVOT, Data Swamp, spurious correlation erklären.
- Konsequenzen von Hype/Misuse für das Feld benennen.

### KOMPAKT ZUM LERNEN

- **Grösse ≠ alles; Qualität & Relevanz zählen.**
- Big Data ≠ Data Science; ~95 % unstrukturiert; SSOT-Mythos → MVOT.
- Data Lake ohne Metadaten = Data Swamp; Vorsicht vor spurious correlations.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Exploratory Data Analysis (EDA)** ist der erste, explorative Schritt, in dem man die Daten **genau verstehen** will, bevor man modelliert. Man schaut sich an: *Welche Werttypen gibt es? Gibt es fehlende Werte oder seltsame Zahlen? Wie sind die Daten verteilt, gibt es Ausreisser?* EDA bildet die Grundlage für sinnvolles **Feature Engineering** und gute Modellentscheidungen.

Eng verbunden sind **Data Cleansing, Parsing und Profiling** (Umgang mit Fehlern, Anomalien, Formatinkonsistenzen) sowie **Pattern Detection, Trend Identification und Anomaly Detection**. EDA hilft, Probleme früh zu erkennen – etwa fehlende Werte, Ausreisser oder Verteilungsschiefen – und so spätere Fehler (z. B. verzerrte Modelle, Bias) zu vermeiden.

### DEFINITIONEN & BEGRIFFE

- **EDA:** systematisches Erkunden/Verstehen der Daten (Struktur, Verteilung, Auffälligkeiten) vor dem Modellieren.
- **Data Profiling:** Analyse von Inhalt/Struktur/Qualität der Daten.
- **Missing Values / Outliers:** fehlende bzw. extreme Werte, die das Modell stören können.
- **Anomaly Detection:** Erkennen ungewöhnlicher Muster/Werte.

### BEISPIEL

Vor dem Training prüft man einen Datensatz: 12 % fehlende Alterswerte, ein paar negative Preise (Fehler), eine stark rechtsschiefe Verteilung. Diese EDA-Erkenntnisse bestimmen, wie man imputiert, bereinigt und skaliert – und verhindert spätere Verzerrungen.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Was ist EDA und warum *vor* dem Modellieren?
- Welche Auffälligkeiten sucht man? (Missing Values, Ausreisser, Verteilungen, Formatfehler).
- Bezug zu Feature Engineering und Data Quality.
- Achtung: EDA-Schritte korrekt nur auf Trainingsdaten anwenden (Data Leakage vermeiden, vgl. Thema 5).

### KOMPAKT ZUM LERNEN

- **EDA = Daten verstehen, bevor man modelliert.**
- Prüfen: Typen, Missing Values, Ausreisser, Verteilungen, Anomalien.
- Grundlage für Feature Engineering; früh Probleme/Bias erkennen.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Ashbys Gesetz wird oft **missverstanden**. Die korrekte Aussage: Um ein System zu steuern, muss der Controller **mindestens so viel Varietät besitzen wie das System** (Requisite Variety). Daraus folgen typische Fehldeutungen, die du erkennen und korrigieren können solltest:

- „**Mehr Varietät ist immer besser / einfach Komplexität hinzufügen.**“ Falsch – man kann ebenso gut die **Umweltvarietät reduzieren/filtern (Attenuation)**, statt nur die eigene zu erhöhen (Amplifikation). Blindes Aufblähen der eigenen Komplexität macht das System selbst unbeherrschbar.
- „**Varietät = Datenmenge/Grösse.**“ Falsch – Varietät meint die **Zahl unterscheidbarer Zustände (Komplexität)**, nicht das Datenvolumen (Bezug zu den Big-Data-Mythen, Thema 23).
- „**Das Gesetz ist eine exakte, quantitative Formel.**“ Es ist v. a. ein **Leitprinzip** der Kybernetik, kein präzises Rechenrezept.
- **Verwechslung von Anpassung und Kontrolle** – beides beruht auf Varietät, adressiert aber unterschiedliche Fragen (vgl. Themen 2 & 11).

Die Konsequenz einer Fehldeutung: man setzt die falsche Strategie ein (z. B. nur Komplexität anhäufen) und läuft in **fatal undercomplexity** oder in unbeherrschbare Eigenkomplexität.

### DEFINITIONEN & BEGRIFFE

- **Korrekte Lesart:** Controllervarietät  $\geq$  Systemvarietät (matchen, nicht maximieren).
- **Amplifikation vs. Attenuation:** eigene Varietät erhöhen vs. Umweltvarietät reduzieren – beide sind legitim.
- **Varietät:** Anzahl unterscheidbarer Zustände ( $\neq$  Datenmenge).

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- „Bedeutet Ashby, dass man immer mehr Komplexität braucht?“ → Nein, Attenuation ist gleichwertig.
- Varietät ist *nicht* gleich Datenvolumen.
- Ashby als Prinzip, nicht als exakte Formel verstehen.
- Folge falscher Deutung: falsche Steuerungsstrategie / fatal undercomplexity.

### KOMPAKT ZUM LERNEN

- Richtig: Varietät **matchen** ( $\geq$ ), nicht blind maximieren.
- Zwei Hebel: Varietät erhöhen *oder* Umwelt filtern.
- Varietät  $\neq$  Datenmenge; Gesetz = Prinzip, keine Formel.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**VUCA** beschreibt herausfordernde Umgebungen, in denen Entscheidungen wegen Instabilität, Unvorhersehbarkeit und Verflechtungen schwierig sind. Der Begriff wurde **ursprünglich vom US-Militär** eingeführt und ist heute in Wirtschaft und KI essenziell.

| Dimension   | Bedeutung                                                                | Beispiel                            |
|-------------|--------------------------------------------------------------------------|-------------------------------------|
| Volatility  | schnelle, unvorhersehbare Veränderung (instabil, nicht zwingend komplex) | plötzliche Lieferketten-Störung     |
| Uncertainty | Zukunft trotz Daten unbekannt                                            | Reaktion eines Konkurrenten         |
| Complexity  | viele vernetzte Variablen, Ursache/Wirkung unklar                        | globale Regulierungs-Compliance     |
| Ambiguity   | unklare Bedeutung, „unknown unknowns“, keine Präzedenz                   | Launch eines radikal neuen Produkts |

Warum es für Data Science zählt: Moderne Data Science arbeitet in genau solchen Bedingungen (volatile Umfeld, unvollständige/verrauschte Daten, hochdimensionale Probleme, unklare Ziele). **Einfache Modelle und fixe Strategien versagen.** Antwort darauf: **Systemdenken/System Dynamics** und ein geschlossener Regelkreis *sense* → *think* → *act* – „Nur wer in einem geschlossenen Loop wahrnimmt, denkt und handelt, kann bestehen.“

### DEFINITIONEN & BEGRIFFE

- **VUCA:** Volatility, Uncertainty, Complexity, Ambiguity – Rahmen für schwierige Entscheidungsumgebungen.
- **Resilienz:** Fähigkeit, unter VUCA stabil/handlungsfähig zu bleiben.
- **Closed Loop (sense–think–act):** wahrnehmen (Daten) → denken (Modelle) → handeln (Policies).

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Alle vier Dimensionen mit **je einem Beispiel** nennen.
- Ursprung (US-Militär) und heutige Relevanz.
- Warum versagen fixe Modelle? Wie hilft System Dynamics?
- Achtung: Dimensionen *nicht* gleichsetzen (vgl. Misconceptions, unten erwähnt).

#### KOMPAKT ZUM LERNEN

- Volatility, **U**ncertainty, **C**omplexity, **A**mbiguity – je 1 Beispiel parat haben.
- VUCA → fixe Modelle versagen → Systemdenken + sense/think/act.
- Jede Dimension braucht einen eigenen Ansatz.

### ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Algorithmen lassen sich danach unterscheiden, **wann** sie „lernen“. **Eager Learners** bauen schon *während des Trainings* ein allgemeines Modell: Sie verarbeiten die gesamten Trainingsdaten vorab, optimieren eine Hypothesenfunktion und **verwerfen die Trainingsdaten danach**. **Lazy Learners (instance-based)** bauen *kein* Modell beim Training, sondern **speichern die Daten** und verschieben die Generalisierung bis zur Anfrage – das „Lernen“ passiert erst zur **Vorhersagezeit**.

|                | Eager Learner                                             | Lazy Learner                                        |
|----------------|-----------------------------------------------------------|-----------------------------------------------------|
| Modellbau      | vorab beim Training                                       | kein Modell; speichert Daten                        |
| Algorithmen    | Logistic Regression, SVM, Decision Trees, Neuronale Netze | KNN (v. a.), Case-Based Reasoning, Local Regression |
| Trainingszeit  | hoch                                                      | niedrig                                             |
| Vorhersagezeit | schnell                                                   | langsam (durchsucht Daten)                          |
| Speicher       | effizient zur Inferenz                                    | hoher Verbrauch                                     |
| Weiteres       | gute Generalisierung bei gutem Training                   | empfindlich gegen Rauschen & irrelevante Features   |

### DEFINITIONEN & BEGRIFFE

- **Eager Learner:** baut vorab ein generelles Modell, verwirft dann die Trainingsdaten.
- **Lazy Learner:** speichert Daten, generalisiert erst bei der Anfrage (instance-based).
- **Hinweis:** Daneben gibt es die *Lernarten* supervised, unsupervised, semi-supervised, reinforcement (vgl. Themen 15/4).

### BEISPIEL

**KNN** (lazy): speichert alle Trainingspunkte; bei einer neuen Anfrage sucht es die k nächsten Nachbarn → langsam zur Vorhersage. **Decision Tree** (eager): baut den Baum einmal beim Training → danach blitzschnelle Vorhersagen.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Eager vs. Lazy definieren und je Algorithmen zuordnen.
- Trade-off Trainingszeit ↔ Vorhersagezeit ↔ Speicher erklären.
- Warum ist KNN ein typischer Lazy Learner?
- Nicht verwechseln mit den Lernarten (supervised etc.).

#### KOMPAKT ZUM LERNEN

- **Eager:** lernt vorab (langsames Training, schnelle Vorhersage) – SVM, Trees, NN.
- **Lazy:** lernt bei Anfrage (schnelles Training, langsame Vorhersage) – KNN.
- Lazy = speicherintensiv & rauschempfindlich.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

**Data Bias** ist jeder **systematische Fehler** in Datenerhebung, -auswahl, -analyse oder -darstellung, der zu **verzerrten, irreführenden oder unfairen Ergebnissen** führt. Bias beginnt oft beim Menschen, wird aber **besonders gefährlich, wenn er durch KI automatisiert und skaliert** wird. Er gefährdet Objektivität, wissenschaftliche Integrität, Fairness und KI-Ethik.

| Bias-Typ                    | Kurzbeschreibung                                                   |
|-----------------------------|--------------------------------------------------------------------|
| Reporting Bias              | extreme/einprägsame Ereignisse überrepräsentiert                   |
| Historic Bias               | alte gesellschaftliche Ungleichheiten stecken in den Daten         |
| Confirmation Bias           | Daten werden gesucht, die die eigene Annahme stützen               |
| Observer Bias               | Erwartungen der Forschenden beeinflussen Erhebung/Deutung          |
| Sampling Bias               | Stichprobe nicht repräsentativ                                     |
| Survivorship Bias           | nur „Erfolge“ betrachtet, Fehlschläge ignoriert                    |
| Data Processing Bias        | Transformation/Cleaning verzerrt Ergebnisse                        |
| Algorithmic Bias            | Modell reproduziert/verstärkt Bias der Trainingsdaten              |
| Intentional Collection Bias | Daten gezielt für ein vorbestimmtes Ergebnis gesammelt             |
| Automation Bias             | Menschen vertrauen automatisierten Ergebnissen zu sehr (vgl. HITL) |

### DEFINITIONEN & BEGRIFFE

- **Data Bias:** systematischer Fehler → verzerrte/unfaire Resultate.
- **Algorithmic Bias:** Modelle lernen und verstärken Verzerrungen der Daten.
- **Automation Bias:** übermässiges Vertrauen in automatisierte Outputs.

### BEISPIEL

Ein Recruiting-Modell, das auf historischen Einstellungsdaten trainiert wird, übernimmt vergangene Diskriminierung (Historic + Algorithmic Bias) und benachteiligt bestimmte Gruppen – unter dem Anschein der „Neutralität“.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Definition Data Bias; warne: Automatisierung skaliert Bias.
- Mehrere Bias-Typen nennen & zuordnen (Sampling, Confirmation, Survivorship, Algorithmic...).
- Risiken: Diskriminierung, Vertrauensverlust, Scheinneutralität, Ethikverstösse (Justiz, Kredit, Hiring).
- Gegenmassnahmen: Transparenz, Annahmen dokumentieren, Erklärbarkeit, Datenqualität, laufendes Monitoring, HITL.

### KOMPAKT ZUM LERNEN

- **Bias = systematischer Fehler → unfaire Ergebnisse.**
- Mensch als Ursprung, KI als Verstärker/Skalierer.
- Bekämpfen: Transparenz, Datenqualität, Erklärbarkeit, Monitoring, Human-in-the-Loop.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Eine Kernfunktion des **Viable System Model (VSM)** ist die **Frühwarnung**: Über seine **anti-oszillatorischen Feedback-Loops** erkennt das System beginnende Instabilität/Schwingungen frühzeitig und dämpft sie, bevor sie eskalieren. So sichern die Loops **Anpassungsfähigkeit, Lernen und Systemgesundheit**. Feedback überwacht laufend den eigenen Zustand und die Leistung und meldet Abweichungen zurück.

Fehlt dieses Feedback oder ist das Systemwissen unvollständig, kommt es zum **Kontrollverlust – ein Feedback-Design-Fehler**. In datenreichen, mehrstufigen CPS wird die Frühwarnung durch Data-Science-Werkzeuge ergänzt: **Anomaly Detection**, **Statistical Process Control (SPC)** (erkennt Prozessabweichungen, sichert Stabilität/Vorhersagbarkeit) und **Complex Event Processing (CEP)** in Echtzeit-Event-Streams. Frühwarnung heisst also: *Abweichungen erkennen, solange Gegensteuern noch möglich ist.*

### DEFINITIONEN & BEGRIFFE

- **Anti-oszillatorische Feedback-Loops**: dämpfen Schwingungen, sichern Stabilität & Lernen → wirken als Frühwarnung.
- **SPC**: Statistical Process Control – erkennt Prozessvariationen früh.
- **Anomaly Detection**: Erkennen ungewöhnlicher Muster als Warnsignal.
- **Feedback-Design-Fehler**: Kontrollverlust durch fehlendes/unvollständiges Feedback.

### BEISPIEL

In einer Produktionslinie zeigen SPC-Kontrollkarten, dass die Streuung eines Prozesses langsam zunimmt. Dieses Frühwarnsignal (Abweichung vom Normalbereich) löst Gegenmassnahmen aus, bevor Ausschuss entsteht – analog zu den dämpfenden Feedback-Loops im VSM.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Wie ermöglicht das VSM Frühwarnung? (anti-oszillatorische Feedback-Loops).
- Was passiert ohne ausreichendes Feedback / bei unvollständigem Systemwissen? (Kontrollverlust = Design-Fehler).
- Welche Data-Science-Werkzeuge unterstützen Frühwarnung? (SPC, CEP, Anomaly Detection).
- Bezug zu System Health, Adaptivität, Lernen.

### KOMPAKT ZUM LERNEN

- **VSM-Feedback = Frühwarnung**: Instabilität früh erkennen & dämpfen.
- Fehlendes Feedback → Kontrollverlust (Design-Fehler).
- Tools: SPC, CEP, Anomaly Detection in Echtzeit.

## ► ERKLÄRUNG DER WICHTIGSTEN KONZEPTE

Data Science mischt Ideen und Methoden aus vielen Feldern – sie ist **transdisziplinär**. „Transdisziplinär“ heisst dabei mehr als nur Kombinieren: Es geht darum, die Felder wirklich **zusammenzubringen**, um komplexe, feldübergreifende Probleme zu lösen. Nötig ist das, weil die Welt komplex ist (VUCA) und Daten immer grösser/vielfältiger werden (Big Data).

| Disziplin              | Beitrag                                                                                         |
|------------------------|-------------------------------------------------------------------------------------------------|
| Mathematik & Statistik | Grundwerkzeuge: Daten zusammenfassen, Muster finden, Ideen testen                               |
| Computer Science & IT  | Algorithmen, Big-Data-Handling (Volume/Variety/Velocity/Veracity), Data Warehouses/Lakes        |
| Domain Knowledge       | Fachwissen, um Problem, Daten & Ergebnisse richtig zu deuten (sonst „solitary analysis“)        |
| Social Science         | Wirkung auf Mensch & Gesellschaft: Fairness, Accountability, Transparenz, Human-Centric AI/HITL |

Cao nennt das Zusammenführen vieler Intelligenzquellen „**X-Intelligence**“: Intelligenz aus mehreren Quellen, zu einem einheitlichen System synthetisiert. Diese Quellen sind: **Environmental, Organizational, Network, Social, Human, Data, Domain, Behavior**. Gute Data Science ist also nicht nur Algorithmik, sondern die Kombination aus menschlichem, sozialem, technischem und kontextuellem Wissen – die Basis von „**Data Science Thinking**“.

### DEFINITIONEN & BEGRIFFE

- **Transdisziplinarität**: echtes Zusammenführen mehrerer Felder (nicht bloss Addition).
- **X-Intelligence (Cao)**: aus vielen Quellen synthetisierte Intelligenz.
- **Solitary Analysis**: Analyse ohne Domänenwissen → Risiko falscher Schlüsse.
- **Data Science Thinking**: mehr als Technik – Probleme aus vielen Blickwinkeln betrachten.

### BEISPIEL

Ein medizinisches Vorhersageprojekt braucht Statistik (Modell), Informatik (Pipeline), ärztliches Domänenwissen (Interpretation) und Sozialwissenschaft (Ethik, Fairness, Patientenwohl). Fehlt eine Säule – etwa das Domänenwissen – drohen nutzlose oder unfaire Ergebnisse.

### PRÜFUNGSRELEVANT / TYPISCHE FRAGEN

- Die vier (bzw. mehr) Disziplinen nennen und je einen Beitrag zuordnen.
- Was bedeutet „transdisziplinär“ – und warum reicht reines Kombinieren nicht?
- Warum ist Domänenwissen kritisch? (sonst „solitary analysis“).
- X-Intelligence & die Intelligenzquellen einordnen; Bezug zu VUCA/Big Data.

### KOMPAKT ZUM LERNEN

- **Data Science = transdisziplinär:** Mathe/Statistik + CS/IT + Domäne + Social Science.
- Domänenwissen ist Pflicht (sonst solitary analysis).
- Cao: **X-Intelligence** aus vielen Quellen → „Data Science Thinking“.