

DSI – Prüfungs-Spick

Alle 30 Themen in der exakten Prüfungsreihenfolge. Pro Thema: **Kern** (Definition), **Merke** (entscheidende Unterscheidungen), **Falle** (typische Single-Choice-Distraktoren). Farbe = Themen-Cluster.

- Systemdenken & Kybernetik
- VUCA & Komplexität
- ML-Methoden
- CPS / Anwendung
- Zielorientiertes Vorgehen
- Verantwortung & Identität

1 VSM vs. System Dynamics

Kern: VSM = rekursive Management-/Steuerungsstruktur für Lebensfähigkeit (Beer). System Dynamics = Simulationsmethode für Verhalten über Zeit (Forrester).

Merke: VSM = Struktur/Steuerung; SD = Stocks, Flows, Feedback, Delays. Beide beruhen auf Feedback & Systemdenken.

Falle: „Beide ignorieren Feedback“ oder „SD ist ein statischer Org-Chart“ = falsch.

2 Ashby Adaptation

Kern: Anpassung = die eigene Varietät an die Umweltvarietät angleichen.

Merke: Zwei Hebel: Amplifikation (eigene Varietät ↑) ODER Attenuation (Umweltvarietät filtern/↓). Data Science erhöht die Kapazität.

Falle: „Nur eigene Varietät reduzieren“ / „bei zu wenig Varietät gedeiht das System automatisch“ = falsch.

3 Data Science Distinction

Kern: Big Data = Daten-Eigenschaften & Infrastruktur (4 V: Volume, Variety, Velocity, Veracity). Data Science = breite, transdisziplinäre Disziplin. Analytics = Teilbereich davon.

Merke: DIKIW: Data → Information → Knowledge → Intelligence → Wisdom.

Falle: „Big Data = Data Science“ = falsch.

4 Real-Time Adaptive Models

Kern: Modelle, die sich laufend aus Streaming-Feedback anpassen (sense → think → act).

Merke: CPS-Event-Streams (schnell, kontinuierlich); RL: model-based (plant voraus) vs. model-free (nur Reward); Online-Learning; Concept Drift.

Falle: „Adaptiv = muss nie aktualisiert werden“ / „braucht kein Feedback“ = falsch.

5 Overfitting

Kern: Overfitting = lernt Rauschen → top im Training, schlecht im Test (hohe Varianz). Underfitting = zu simpel, schlecht überall (hoher Bias).

Merke: Bias-Variance-Tradeoff (Sweet Spot). Gegenmittel: einfacheres Modell, mehr Daten, Regularisierung, Cross-Validation. Data Leakage → Schein-gut.

Falle: „Mit MEHR Komplexität beheben“ = falsch.

6 Visualization

Kern: Visualisierungen können täuschen: abgeschnittene Achse, falsche Vollständigkeit, Emotionen statt Information.

Merke: Braucht Visual Literacy; Sender-Empfänger-Problem; „True & Fair View“ = korrekt UND angemessen interpretierbar. Dashboards bekämpfen Data Overload.

Falle: „Gut gestaltet = kann nie täuschen“ / „immun gegen Bias“ = falsch.

7 Complexity Examples

Kern: Komplexität = viele interdependente Variablen, unklare Ursache/Wirkung (NICHT bloss „kompliziert“).

Merke: CPS-Daten: large-scale/high-dim, real-time, mixed sources, noise, sparsity, heterogen, Non-IID (Abhängigkeiten über Zeit/Kontext).

Falle: „Volle Übersicht/Kontrolle möglich“ / „komplex = nur viele Teile“ = falsch.

8 Class Weighting

Kern: Minderheitsklasse im Loss höher gewichten – die Daten bleiben unverändert.

Merke: Abgrenzung: SMOTE (synthetisch interpolieren), Oversampling (duplizieren), Undersampling (Mehrheit verkleinern).

Falle: „Dupliziert/löscht Datenzeilen“ = falsch (das ist Sampling).

9 Target-Oriented Action

Kern: Vom Ziel her arbeiten; am Ende eine konkrete Aktion (sense → think → act).

Merke: Ziele messbar machen, Stakeholder ausrichten; Ergebnis = „actionable knowledge“.

Falle: „Data-first, das Ziel ergibt sich später“ = falsch.

10 Explainability of Models

Kern: XAI erklärt das WARUM einer KI-Entscheidung → stärkt Vertrauen & Transparenz.

Merke: Gut = interaktiv + nutzerspezifisch; Foundation-Modelle schwer interpretierbar (grosse, opake Parameterräume); Traceability = auditierbar.

Falle: „Black-Box ideal für High-Stakes-Entscheidungen“ = falsch.

11 Ashby Control

Kern: Steuerung gelingt nur, wenn der Regler ≥ Varietät des Systems hat.

Merke: Basis: Kybernetik + Systemtheorie; modellbasierte Steuerung. Cyber-Layer: CEP (Muster in Streams), SPC (Prozessabweichungen).

Falle: „Regler mit weniger Varietät steuert das System trotzdem voll“ = falsch.

12 Viable System Model

Kern: Rekursive Struktur für lebensfähige Systeme; anti-oszillatorische Feedback-Loops → Anpassung, Lernen, Systemgesundheit.

Merke: Subsysteme regulieren sich gegenseitig; Basis des St. Gallen Management-Modells; passt auf mehrstufige CPS.

Falle: „Linearer Plan ohne Feedback/Rekursion“ = falsch.

13 Class Imbalance

Kern: Ungleiche Klassen → Accuracy täuscht (Mehrheitsklasse-Vorhersage wirkt gut, Minderheit wird ignoriert).

Merke: Lösungen: Under-/Oversampling, SMOTE, Class Weighting. Besser messen: Precision/Recall/F1. Bsp: Fraud, seltene Krankheit.

Falle: „Hohe Accuracy = Minderheit gut erkannt“ = falsch.

14 Uncertainty Scenarios

Kern: Uncertainty = Zukunft unbekannt TROTZ vorhandener Daten.

Merke: ≠ Volatility (schnell/instant), ≠ Complexity (viele Variablen), ≠ Ambiguity (unklare Bedeutung/keine Präzedenz). Antwort: Szenarien, sense-model-respond.

Falle: „Uncertainty = gar keine Daten / Analyse unmöglich“ = falsch.

15 Unsupervised Learning

Kern: Unlabelte Daten → verborgene Muster/Gruppen selbst finden.

Merke: Aufgaben: Clustering & Pattern Discovery; keine Labels = billiger, aber schwerer zu evaluieren. Algorithmen: K-Means u.ä.

Falle: „Braucht Labels“ / „= supervised learning“ = falsch.

16 Requisite Variety

Kern: Ashbys Gesetz: „Only variety can absorb variety“ – Regler braucht $\geq$ Varietät des Systems, sonst dominiert die Umwelt.

Merke: Varietät = Anzahl unterscheidbarer Zustände (Komplexitätsmass); zu wenig = „fatal undercomplexity“.

Falle: „Varietät = Datenmenge“ / „mehr Daten = Kontrolle“ = falsch.

17 System Dynamics

Kern: Simulation des Systemverhaltens über Zeit (qualitativ + quantitativ).

Merke: Stocks (Bestand) vs. Flows (Rate), Delays, Nichtlinearität; balancing (–, dämpft) vs. reinforcing (+, verstärkt). Tools: CLD/Stock-Flow, Vensim. Bsp: Bullwhip.

Falle: „Statisch/zeitlos“ / „reinforcing-Loops stabilisieren“ = falsch.

18 Smart Factory

Kern: CPS-basierte, vernetzte Produktion mit Echtzeit-Monitoring/-Steuerung (Industrie 4.0).

Merke: MES verbindet Maschine (physisch) ↔ ERP (cyber). Data Science: Predictive Maintenance, Anomaly Detection, Stream Processing.

Falle: „Offline / feste Schedules ohne Daten“ = falsch.

19 Performance Model-Evaluation

Kern: Accuracy täuscht bei Imbalance → Precision/Recall/F1 verwenden.

Merke: Precision = richtig unter VORHERGESAGTEN Positiven; Recall = gefunden unter ECHTEN Positiven; Confusion Matrix; ROC (Diagonale = Zufall); CRISP-DM-Evaluation.

Falle: „Recall = Anteil richtiger unter vorhergesagten Positiven“ = falsch (das ist Precision).

20 Unsupervised Algorithm

Kern: K-Means (Centroid = Mittelwert) – K-Medoids (reales Objekt, robust ggü. Ausreißern) – Fuzzy C-Means (soft, Mehrfachzugehörigkeit).

Merke: k wird vorab gewählt; keine Labels nötig.

Falle: „Fuzzy C-Means erzwingt genau ein Cluster“ / „braucht Labels“ = falsch.

21 Target Centric Approach

Kern: Strukturierte, iterative Methode; verfeinert Erkenntnisse laufend (nicht linear); alles um Ziel/Subjekt herum.

Merke: Merkmale: goal-, subject-, customer-orientation, priority setting. Bsp: „Customer 360“. = Target-Centric Framing.

Falle: „Data-first / rein system-zentriert“ = falsch.

22 Clustering & Network Analysis

Kern: Clustering = ähnliche Punkte gruppieren. Network Analysis = Verbindungen analysieren (Knoten = Entities, Kanten = Relationships).

Merke: Beide unsupervised/explorativ, keine Labels; Communities im Graph $\approx$ Cluster; „Network“ als Intelligenzquelle, „Relationships“ im Data DNA.

Falle: „Beide brauchen gelabelte Daten“ = falsch.

23 Hype Myths in Data Science

Kern: Mythen: „nur Volume zählt“, „mehr Daten immer besser“, „Big Data = Data Science“, „Golden Record/SSOT automatisch“, „Data Lake per se wertvoll“.

Merke: Wahr: ~95% unstrukturiert, Veracity essenziell, MVOT realistischer, ohne Metadaten → Data Swamp; Vorsicht vor spurious correlations.

Falle: Einen Mythos für eine wahre Aussage halten (oder umgekehrt).

24 EDA

Kern: Exploratory Data Analysis = Daten VERSTEHEN vor dem Modellieren (Typen, Missing Values, Ausreisser, Verteilungen).

Merke: Data Profiling/Cleansing; Grundlage für Feature Engineering; Anomaly Detection erkennt Auffälliges früh.

Falle: „EDA-Schritte mit Testdaten“ = Data Leakage; „bei grossen Daten überspringen“ = falsch.

25 Ashby Misinterpretation

Kern: Richtig: Varietät MATCHEN ($\geq$), via Amplifikation ODER Attenuation; Ashby ist ein Leitprinzip, keine exakte Formel.

Merke: Fehldeutungen erkennen: „immer mehr Komplexität hinzufügen“, „Varietät = Datenmenge“, „exakte Rechenformel“.

Falle: Diese drei Fehldeutungen als „richtig“ markieren = falsch.

26 VUCA environment

Kern: Volatility (schnell/instabil), Uncertainty (unbekannt trotz Daten), Complexity (viele Variablen), Ambiguity (unklar/keine Präzedenz). Ursprung: US-Militär.

Merke: Fixe Modelle versagen → Systemdenken, sense-think-act; jede Dimension braucht einen eigenen Ansatz.

Falle: „Die 4 Dimensionen sind austauschbar“ / „Vorbereitung ist sinnlos“ = falsch.

27 Type of learner

Kern: Eager Learner: Modell vorab (langsames Training, schnelle Vorhersage) – SVM, Decision Trees, LogReg, NN. Lazy Learner: speichert Daten, generalisiert bei Anfrage – KNN.

Merke: Lazy = langsame Vorhersage, hoher Speicher, rauschempfindlich. Eager = speichereffizient zur Inferenz.

Falle: „KNN = eager“ / „Decision Tree = lazy“ = falsch.

28 Biases

Kern: Data Bias = systematischer Fehler → verzerrte/unfaire Ergebnisse; beginnt beim Menschen, wird durch KI skaliert.

Merke: Typen: Sampling (unrepräsentativ), Confirmation (bestätigt Vorannahme), Survivorship (nur Erfolge), Historic (alte Ungleichheit), Algorithmic (verstärkt), Automation (über-vertrauen).

Falle: „KI entfernt Bias“ / „anonymisiert = kein Re-ID-Risiko“ / „neutral aussehen = kein Bias“ = falsch.

29 VSM Early Warning

Kern: Anti-oszillatorische Feedback-Loops erkennen & dämpfen Instabilität früh (Frühwarnung).

Merke: Werkzeuge: SPC (steigende Prozessvariation), Anomaly Detection, CEP in Echtzeit. Fehlendes/unvollständiges Feedback → Kontrollverlust (Design-Fehler).

Falle: „Feedback entfernen verbessert Frühwarnung“ / „nach Deployment unnötig“ = falsch.

30 Interdisciplinarity in Data Science

Kern: Transdisziplinär: Mathe/Statistik + Computer Science/IT + Domänenwissen + Sozialwissenschaft; echtes Integrieren, nicht nur Kombinieren.

Merke: Domänenwissen ist Pflicht (sonst „solitary analysis“). Cao: „X-Intelligence“ (viele Intelligenzquellen). Getrieben von VUCA + Big Data.

Falle: „Nur Statistik / nur Software Engineering“ / „Sozialwissenschaft irrelevant“ = falsch.